

preview

group 2

2025-11-04

1. 簡介目的

預測各 YouBike 站點的租借量／還車量，目的是為了正確預測派出的補車人數，以提升車輛調度效率，降低人力成本；並且從中理解時段與天氣變數對流量的影響。

2. 預測使用的資料

(1) 依時間排列：日期、小時

(2) 站點資訊：每個站的車位總數、每小時借車量、還車量...


(3) 天氣資訊：該小時的降雨量、溫度、風速...

(4) 新增 dummy variable：尖峰時段、假日、深夜、下雨、高溫、強風...



```
## # A tibble: 5 x 8
##   station          date      hour borrow_count return_count station_pressure
##   <chr>          <date>    <dbl>      <dbl>      <dbl>          <dbl>
## 1 捷運公館站(2號出口)~ 2024-03-01      0          15           5           1018.
## 2 捷運公館站(2號出口)~ 2024-03-01      1           2           0           1021.
## 3 捷運公館站(2號出口)~ 2024-03-01      2           1           1           1020.
## 4 捷運公館站(2號出口)~ 2024-03-01      3           1           0           1020.
## 5 捷運公館站(2號出口)~ 2024-03-01      4           1           0           1020.
## # i 2 more variables: temperature <dbl>, humidity <dbl>
```


3. 對應變數 (y) 造成影響的自變數 (x)

(1) 是否尖峰：8 點, 9 點, 17 點, 18 點



各種天氣情形的樣本分佈





(1) 是否降雨： $>0\text{mm}$

(2) 是否高溫： $>25^{\circ}\text{C}$

(3) 是否強風： $>3\text{m/s}$


```
## # A tibble: 2 x 3
##   rain_any median_borrow    n
##   <int>      <dbl> <int>
## 1     0          6 17503
## 2     1          6  1402
```

```
## # A tibble: 2 x 3
##   temp_hot median_borrow    n
##   <int>      <dbl> <int>
## 1     0          5 10806
## 2     1          9  8099
```


```
## # A tibble: 2 x 3
##   wind_strong median_borrow    n
##   <int>      <dbl> <int>
## 1     0          6 14556
## 2     1          8  4349
```

```
## Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.  
## i Please use `linewidth` instead.  
## This warning is displayed once every 8 hours.  
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was  
## generated.
```


```
## Warning: Removed 1223 rows containing non-finite outside the scale range  
## (`stat_density()`).
```



```
## Warning: Removed 1223 rows containing non-finite outside the scale range  
## (`stat_density()`).
```



```
## Warning: Removed 1223 rows containing non-finite outside the scale range
## (`stat_density()`).
```



4. 預測模型.

使用 Random Forest 模型

分別預測 10 個站點各自的還車量與借車量

共訓練了 20 個模型

```
df_merged <- read_csv("df_merged.csv")
```

```
## Rows: 18905 Columns: 22
## -- Column specification -----
## Delimiter: ","
## chr   (1): station
## dbl   (15): hour, borrow_count, return_count, station_pressure, temperature, ...
## lgl   (5): is_holiday_taipei, is_peak_morning, is_peak_evening, is_peak_any,...
## date  (1): date
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```

set.seed(42)
# ==== 基本設定 ====
dt <- as.data.table(df_merged)
targets <- c("borrow_count", "return_count")
exclude_cols <- c("station", "date", "hour", targets)
features <- setdiff(names(dt), exclude_cols)
K <- 5 # blocked 5-fold, 每折測試 20%

# 字串轉因子 (一次處理)
for (nm in features) if (is.character(dt[[nm]])) dt[, (nm) := as.factor(get(nm))]

stations <- unique(dt$station)

# ==== 主程式：僅計算 pooled 指標 ====
out_list <- list()

for (st in stations) {
  d <- dt[station == st][order(date, hour)]
  n <- nrow(d)
  if (n < 80) next # 測試集要有 20% 的量

  # 5 個連續測試區段
  cuts <- floor(n * (0:K) / K)
  test_ranges <- lapply(seq_len(K), function(i) c(cuts[i] + 1L, if (i < K) cuts[i+1L] else n))

  for (y in targets) {
    fml <- as.formula(paste(y, "~", paste(features, collapse = " + ")))

    # 累計器 (只為 pooled 指標)
    sse_total <- 0
    sae_total <- 0
    test_amount <- 0
    sum_y <- 0
    sum_y2 <- 0

    for (i in seq_len(K)) {
      te_st <- test_ranges[[i]][1]
      te_en <- test_ranges[[i]][2]
      te_idx <- te_st:te_en
      tr_idx <- setdiff(seq_len(n), te_idx)
      if (length(te_idx) < 5 || length(tr_idx) < 10) next

      tr <- d[tr_idx]
      te <- d[te_idx]

      rf <- ranger(
        formula = fml,
        data = tr,
        num.trees = 1000, # 較快、CV 夠用
        importance = "none",
        num.threads = 0, # 用滿 CPU
        respect.unordered.factors = "order",

```



```

    seed      = 42 + i
  )

  pred <- predict(rf, te)$predictions
  y_te <- te[[y]]

  err <- y_te - pred
  sse_total <- sse_total + sum(err^2)
  sae_total <- sae_total + sum(abs(err))
  test_amount <- test_amount + length(y_te)
  sum_y <- sum_y + sum(y_te)
  sum_y2 <- sum_y2 + sum(y_te^2)
}

if (test_amount > 0) {
  ybar_all <- sum_y / test_amount
  tss_total <- sum_y2 - test_amount * (ybar_all^2)
  R2 <- if (tss_total > 0) 1 - (sse_total / tss_total) else NA_real_
  RMSE <- sqrt(sse_total / test_amount)
  MAE <- sae_total / test_amount
} else {
  R2 <- RMSE <- MAE <- NA_real_
}

out_list[[paste(st, y, sep = " :: ")] <- data.table(
  station = st, target = y,
  RMSE = RMSE,
  MAE = MAE,
  R2 = R2,
  test_amount = test_amount
)
}
}

metrics_summary_min <- rbindlist(out_list, use.names = TRUE, fill = TRUE)
df_metrics <- as.data.frame(metrics_summary_min)
print(df_metrics)

```

##	station	target	RMSE	MAE	R2	test_amount
## 1	捷運公館站(2號出口)	borrow_count	19.794790	14.775371	0.7339140	2098
## 2	捷運公館站(2號出口)	return_count	19.419671	14.329650	0.8293512	2098
## 3	新生南路三段52號前	borrow_count	1.992766	1.510071	0.5566737	1780
## 4	新生南路三段52號前	return_count	1.993421	1.479410	0.6652788	1780
## 5	新生南路三段66號前	borrow_count	3.596320	2.609181	0.6482828	1803
## 6	新生南路三段66號前	return_count	3.509943	2.525888	0.6637605	1803
## 7	新生南路三段82號前	borrow_count	4.815898	3.461009	0.6711758	1947
## 8	新生南路三段82號前	return_count	4.739784	3.392227	0.6738341	1947
## 9	第二學生活動中心	borrow_count	4.129332	3.081657	0.6414232	1817
## 10	第二學生活動中心	return_count	4.124085	3.056913	0.6418374	1817
## 11	臺大男七舍前	borrow_count	2.587343	1.959002	0.6737828	1982
## 12	臺大男七舍前	return_count	2.525055	1.953247	0.6500618	1982
## 13	臺灣科技大學側門	borrow_count	7.735005	5.518152	0.8559675	2038

## 14	臺灣科技大學側門	return_count	7.605790	5.477869	0.7533524	2038
## 15	臺灣科技大學正門	borrow_count	2.793928	1.971604	0.7928150	1709
## 16	臺灣科技大學正門	return_count	2.666246	1.936308	0.6359009	1709
## 17	辛亥復興路口西北側	borrow_count	4.869943	3.397750	0.6798561	1884
## 18	辛亥復興路口西北側	return_count	4.795325	3.346648	0.6551013	1884
## 19	銘傳國小側門	borrow_count	3.031907	2.241539	0.6324975	1847
## 20	銘傳國小側門	return_count	3.024425	2.262419	0.5883038	1847

5. 驗證.

使用 cross validation ,K-fold K=5

每個 fold 將資料全部的 2 成用來 test , 8 成用來 train

##	station	target	RMSE	MAE	R2
## 1	捷運公館站(2號出口)	borrow_count	19.794790	14.775371	0.7339140
## 2	捷運公館站(2號出口)	return_count	19.419671	14.329650	0.8293512
## 3	新生南路三段52號前	borrow_count	1.992766	1.510071	0.5566737
## 4	新生南路三段52號前	return_count	1.993421	1.479410	0.6652788
## 5	新生南路三段66號前	borrow_count	3.596320	2.609181	0.6482828
## 6	新生南路三段66號前	return_count	3.509943	2.525888	0.6637605
## 7	新生南路三段82號前	borrow_count	4.815898	3.461009	0.6711758
## 8	新生南路三段82號前	return_count	4.739784	3.392227	0.6738341
## 9	第二學生活動中心	borrow_count	4.129332	3.081657	0.6414232
## 10	第二學生活動中心	return_count	4.124085	3.056913	0.6418374
## 11	臺大男七舍前	borrow_count	2.587343	1.959002	0.6737828
## 12	臺大男七舍前	return_count	2.525055	1.953247	0.6500618
## 13	臺灣科技大學側門	borrow_count	7.735005	5.518152	0.8559675
## 14	臺灣科技大學側門	return_count	7.605790	5.477869	0.7533524
## 15	臺灣科技大學正門	borrow_count	2.793928	1.971604	0.7928150
## 16	臺灣科技大學正門	return_count	2.666246	1.936308	0.6359009
## 17	辛亥復興路口西北側	borrow_count	4.869943	3.397750	0.6798561
## 18	辛亥復興路口西北側	return_count	4.795325	3.346648	0.6551013
## 19	銘傳國小側門	borrow_count	3.031907	2.241539	0.6324975
## 20	銘傳國小側門	return_count	3.024425	2.262419	0.5883038

6. 觀察

就觀察 R^2 而言，有的站預測很好有的很差

低 R^2 的站總車位數小，基礎借還車流量小，流量在不同時間的變化也很小

雖然預測不準，但預測值與實際值的誤差可能不大

##	station	target	R2	total
## 1	捷運公館站(2號出口)	borrow_count	0.7339140	99
## 2	捷運公館站(2號出口)	return_count	0.8293512	99

## 3	新生南路三段52號前	borrow_count	0.5566737	17
## 4	新生南路三段52號前	return_count	0.6652788	17
## 5	新生南路三段66號前	borrow_count	0.6482828	16
## 6	新生南路三段66號前	return_count	0.6637605	16
## 7	新生南路三段82號前	borrow_count	0.6711758	20
## 8	新生南路三段82號前	return_count	0.6738341	20
## 9	第二學生活動中心	borrow_count	0.6414232	25
## 10	第二學生活動中心	return_count	0.6418374	25
## 11	臺大男七舍前	borrow_count	0.6737828	20
## 12	臺大男七舍前	return_count	0.6500618	20
## 13	臺灣科技大學側門	borrow_count	0.8559675	99
## 14	臺灣科技大學側門	return_count	0.7533524	99
## 15	臺灣科技大學正門	borrow_count	0.7928150	50
## 16	臺灣科技大學正門	return_count	0.6359009	50
## 17	辛亥復興路口西北側	borrow_count	0.6798561	16
## 18	辛亥復興路口西北側	return_count	0.6551013	16
## 19	銘傳國小側門	borrow_count	0.6324975	7
## 20	銘傳國小側門	return_count	0.5883038	7

7. 結論.

(1) 不需要預測淨流量

(2) R^2 很低的站依然值得預測